



# شبکه های اجتماعی و اقتصادی

دانشکده مهندسی کامپیوتر  
مریم رمضانی  
بهار ۱۴۰۴

۱۲ اسفند ۱۴۰۳

## کوییز اول

آمار و احتمال، جبرخطی

۱. هر کوییز 0.5 نمره از بارم کلی درس دارد.

۲. می توانید بدون حل یک سوال، از نتیجه اش در حل سوالات دیگر استفاده نمایید.

پرسش ۱ (۲۰ نمره)

- (آ) اثبات کنید عبارت  $E[(X - c)^2]$  زمانی مینیمم میشود که  $c = \mu$  باشد.  
(ب) اثبات کنید عبارت  $E[|X - c|]$  زمانی مینیمم می شود که  $c$  برابر با میانه  $X$  باشد.

پاسخ:

(آ) عبارت  $E[(X - c)^2]$  را بسط می دهیم:

$$\begin{aligned} E[(X - c)^2] &= E[X^2 - 2cX + c^2] \\ &= E[X^2] - 2cE[X] + c^2 \end{aligned}$$

برای یافتن مقدار مینیمم، مشتق نسبت به  $c$  را می گیریم و آن را برابر با صفر قرار می دهیم:

$$\frac{d}{dc} E[(X - c)^2] = -2E[X] + 2c = 0$$

حل برای  $c$ :

$$c = E[X] = \mu$$

- مشتق دوم برابر است با  $\frac{d^2}{dc^2} E[(X - c)^2] = 2 > 0$ ، که تأیید می کند این یک مینیمم است.  
بنابراین،  $E[(X - c)^2]$  زمانی مینیمم می شود که  $c = \mu$  باشد.  
(ب) فرض کنید  $F_X(x)$  تابع توزیع تجمعی  $X$  باشد.

$$\begin{aligned} E[|X - c|] &= \int_{-\infty}^{\infty} |x - c| dF_X(x) \\ &= \int_{-\infty}^c (c - x) dF_X(x) + \int_c^{\infty} (x - c) dF_X(x) \end{aligned}$$

مشتق گیری نسبت به  $c$ :

$$\begin{aligned} \frac{d}{dc} E[|X - c|] &= \int_{-\infty}^c dF_X(x) - \int_c^{\infty} dF_X(x) \\ &= F_X(c) - (1 - F_X(c)) = 2F_X(c) - 1 \end{aligned}$$

قرار دادن این عبارت برابر با صفر:

$$\begin{aligned} 2F_X(c) - 1 &= 0 \\ F_X(c) &= \frac{1}{2} \end{aligned}$$

این بدان معنی است که  $c$  مقداری است که برای آن  $P(X \leq c) = \frac{1}{2}$ ، که تعریف میانه  $X$  است.  
بنابراین،  $E[|X - c|]$  زمانی مینیمم می شود که  $c$  برابر با میانه  $X$  باشد.

نرم فروبنیوس برای ماتریس  $A \in \mathbb{R}^{m \times n}$  به صورت زیر تعریف می‌شود:

$$\|A\|_F = \sqrt{\text{tr}\{A^T A\}}$$

(آ) ثابت کنید:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |A_{ij}|^2}.$$

(ب) اگر مقادیر تکین ماتریس  $A$  را با  $\sigma_1, \sigma_2, \dots, \sigma_r$  نشان دهیم، ثابت کنید:

$$\|A\|_F = \sqrt{\sum_{i=1}^r \sigma_i^2}.$$

(ج) ثابت کنید:

$$\sigma_{\max}(A) \leq \|A\|_F \leq \sqrt{r} \sigma_{\max}(A).$$

پاسخ:

(آ) با تعریف شروع می‌کنیم:  $\|A\|_F = \sqrt{\text{tr}\{A^T A\}}$

عنصر  $(i, j)$  ماتریس  $A^T A$  عبارت است از:

$$(A^T A)_{ij} = \sum_{k=1}^m A_{ki} \cdot A_{kj}$$

trace ماتریس  $A^T A$  عبارت است از:

$$\text{tr}\{A^T A\} = \sum_{i=1}^n (A^T A)_{ii} = \sum_{i=1}^n \sum_{k=1}^m A_{ki} \cdot A_{ki} = \sum_{i=1}^n \sum_{k=1}^m |A_{ki}|^2$$

تغییر اندیس‌ها:

$$\text{tr}\{A^T A\} = \sum_{k=1}^m \sum_{i=1}^n |A_{ki}|^2 = \sum_{i=1}^n \sum_{j=1}^n |A_{ij}|^2$$

$$\|A\|_F = \sqrt{\text{tr}\{A^T A\}} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |A_{ij}|^2}$$

(ب) با استفاده از تجزیه SVD داریم:  $A = U \Sigma V^T$ ، که در آن:

- $U$  یک ماتریس متعامد  $m \times m$  است
- $\Sigma$  یک ماتریس قطری  $m \times n$  با مقادیر منفرد  $\sigma_1, \sigma_2, \dots, \sigma_r$  بر روی قطر است
- $V$  یک ماتریس متعامد  $n \times n$  است

جایگذاری در تعریف نرم فروبنیوس:

$$\begin{aligned} \|A\|_F &= \sqrt{\text{tr}\{A^T A\}} = \sqrt{\text{tr}\{(U \Sigma V^T)^T (U \Sigma V^T)\}} \\ &= \sqrt{\text{tr}\{V \Sigma^T U^T U \Sigma V^T\}} \end{aligned}$$

از آنجایی که  $U^T U = I$ ، متعامد است،

$$\|A\|_F = \sqrt{\text{tr}\{V \Sigma^T \Sigma V^T\}}$$

با استفاده از ویژگی‌های trace و اینکه  $V$  متعامد است ( $V^T V = I$ ):

$$\|A\|_F = \sqrt{\text{tr}\{\Sigma^T \Sigma V^T V\}} = \sqrt{\text{tr}\{\Sigma^T \Sigma\}}$$

از آنجایی که  $\Sigma^T \Sigma$  قطری است و  $\sigma_i^2$  روی قطر آن قرار دارد:

$$\|A\|_F = \sqrt{\sum_{i=1}^r \sigma_i^2}$$

(ج) برای نامساوی سمت چپ: از قسمت (ب) داریم:  $\|A\|_F = \sqrt{\sum_{i=1}^r \sigma_i^2}$   
 از آنجایی که همه  $\sigma_i^2$  نامنفی هستند و با فرض  $\sigma_1 = \sigma_{\max}(A)$ :

$$\sum_{i=1}^r \sigma_i^2 \geq \sigma_1^2$$

با گرفتن جذر:

$$\|A\|_F \geq \sigma_1 = \sigma_{\max}(A)$$

برای نامساوی سمت راست: از آنجایی که  $\sigma_i \leq \sigma_1$  برای همه  $i$  ها:

$$\sum_{i=1}^r \sigma_i^2 \leq \sum_{i=1}^r \sigma_1^2 = r\sigma_1^2$$

با گرفتن جذر:

$$\|A\|_F \leq \sqrt{r}\sigma_1 = \sqrt{r}\sigma_{\max}(A)$$

بنابراین:  $\sigma_{\max}(A) \leq \|A\|_F \leq \sqrt{r}\sigma_{\max}(A)$

**پرسش ۳** (۱۰ نمره) ماتریس های  $U$  و  $V$  در SVD Decomposition چه معنی و کاربردی دارند؟

**پاسخ:**

در تجزیه SVD ماتریس  $A \in \mathbb{R}^{m \times n}$  به صورت  $A = U\Sigma V^T$ :

**ماتریس  $U$  (بردارهای منفرد چپ):**

- $U$  یک ماتریس متعامد  $m \times m$  است که ستون های آن بردارهای ویژه  $AA^T$  هستند.
- $r$  ستون اول یک مبنای متعامد برای فضای ستونی  $A$  تشکیل می دهند.
- ستون های باقی مانده مبنایی برای فضای پوچ  $A$  تشکیل می دهند.

**ماتریس  $V$  (بردارهای منفرد راست):**

- $V$  یک ماتریس متعامد  $n \times n$  است که ستون های آن بردارهای ویژه  $A^T A$  هستند.
- $r$  ستون اول یک مبنای متعامد برای فضای ردیفی  $A$  تشکیل می دهند.
- ستون های باقی مانده مبنایی برای فضای پوچ  $A$  تشکیل می دهند.

**کاربردها:**

- تبدیل خطی:**  $U$  و  $V$  مبنای متعامد را برای دامنه و هم دامنه فراهم می کنند، و  $\Sigma$  فاکتورهای مقیاس بندی را می دهد.
- تحلیل مولفه های اصلی:** ستون های  $V$  مولفه های اصلی را نشان می دهند (جهت های حداکثر واریانس).
- فشرده سازی داده:** برش به  $k$  مقدار منفرد برتر، بهترین تقریب رتبه- $k$  را می دهد.
- شبه وارون:** محاسبه  $A^+ = V\Sigma^+U^T$  برای حل معادلات کمترین مربعات.
- تحلیل معنایی پنهان:** در پردازش زبان طبیعی، آن ها "مفاهیم پنهان" را در مجموعه های سند نشان می دهند.
- پردازش سیگنال:** مبنای توابع متعامد را برای تجزیه سیگنال فراهم می کنند.

در اصل،  $U$  و  $V$  ساختار اساسی تبدیل خطی نشان داده شده توسط  $A$  را ضبط می کنند، که آن ها را برای کاهش ابعاد، تحلیل داده ها و حل سیستم های خطی ارزشمند می سازد.